Transfermarkt

```
library(dplyr)
library(ggplot2)

options(scipen = 999)

load("data/transfermarkt.RData")
```

glimpse(transfermarkt)

```
## Rows: 7,030
## Columns: 36
## $ ano campeonato
             <int> 2003, 2003, 2003, 2003, 2003, 2003, 2003, 200~
             <date> 2003-03-29, 2003-03-29, 2003-03-30, 2003-03-~
## $ data
             <chr> "08:00", "08:00", "09:00", "09:00", "09:00", ~
## $ horario
## $ rodada
             <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 2, 2, ~
## $ estadio
             <chr> "Estádio Brinco de Ouro da Princesa", "Arena ~
             ## $ arbitro
## $ publico
             ## $ publico_max
             ## $ time_man
             <chr> "Guarani", "Atlético-PR", "Flamengo", "Goiás ~
             <chr> "Vasco da Gama", "Grêmio", "Coritiba FC", "Pa~
## $ time_vis
             ## $ tecnico_man
## $ tecnico vis
             ## $ colocacao man
             ## $ colocacao vis
             ## $ idade media titular vis
             <int> 4, 2, 1, 2, 1, 2, 2, 0, 2, 1, 2, 0, 1, 0, 0, ~
## $ gols_man
             <int> 2, 0, 1, 2, 1, 0, 2, 0, 2, 1, 2, 3, 1, 0, 1, ~
## $ gols_vis
             ## $ gols_1_tempo_man
## $ gols_1_tempo_vis
             ## $ escanteios_man
             ## $ escanteios_vis
             ## $ faltas_man
             ## $ faltas_vis
## $ chutes_bola_parada_man
             ## $ chutes_bola_parada_vis
             ## $ defesas man
             ## $ defesas_vis
             ## $ impedimentos_man
## $ impedimentos_vis
             ## $ chutes_man
             ## $ chutes vis
```

```
## $ chutes_fora_man
                         ## $ chutes_fora_vis
                          transfermarkt = transfermarkt %>%
 filter(ano campeonato >= 2015,
       !is.na(gols man))
transfermarkt %>%
 filter(time_man == "Flamengo") %>%
 select(data, valor_equipe_titular_man)
## # A tibble: 114 x 2
##
     data
              valor_equipe_titular_man
##
     <date>
                               <int>
## 1 2015-05-17
                            26000000
## 2 2015-05-31
                            30500000
## 3 2015-06-06
                            35500000
## 4 2015-06-20
                            28250000
## 5 2015-07-05
                            22250000
## 6 2015-07-12
                            24000000
## 7 2015-07-18
                            26000000
## 8 2015-08-02
                            30750000
## 9 2015-08-13
                            22000000
## 10 2015-08-23
                            28500000
## # ... with 104 more rows
sum(is.na(transfermarkt$valor_equipe_titular_man))/nrow(transfermarkt)
```

[1] 0.04607284

```
sum(is.na(transfermarkt$valor_equipe_titular_vis))/nrow(transfermarkt)
```

[1] 0.04607284

Existem partidas com missing nos valores de mercado, repetir os valores da última partida não missing ou usar a média da temporada até então?

Acho que usar a média da temporada dá menos problema pois evita problema de jogos com time titular após jogos com time reserva.

```
teams = sort(unique(transfermarkt$time_man))
teams
```

```
[1] "América-MG"
                          "Athletico-PR"
                                           "Atlético-GO"
                                                             "Atlético-MG"
                          "Avaí FC"
                                                             "Ceará SC"
##
    [5] "Atlético-PR"
                                           "Botafogo"
  [9] "Chapecoense"
                          "Corinthians"
                                           "Coritiba FC"
                                                             "Cruzeiro"
                                                             "Figueirense FC"
## [13] "CSA"
                          "EC Bahia"
                                           "EC Vitória"
## [17] "Flamengo"
                          "Fluminense"
                                           "Fortaleza"
                                                             "Goiás EC"
## [21] "Grêmio"
                          "Internacional"
                                           "Joinville-SC"
                                                             "Palmeiras"
## [25] "Paraná"
                          "Ponte Preta"
                                           "RB Bragantino"
                                                             "Santa Cruz"
## [29] "Santos FC"
                         "São Paulo"
                                           "Sport Recife"
                                                             "Vasco da Gama"
```

Existem "Athletico-PR" e "Atlético-PR", vou padronizar.

```
transfermarkt$time_man[which(transfermarkt$time_man == "Atlético-PR")] = "Athletico-PR"
transfermarkt$time_vis[which(transfermarkt$time_vis == "Atlético-PR")] = "Athletico-PR"
```

```
team = NULL
season = NULL
mean_value = NULL
for(t in teams) {
  for(s in 2015:2020) {
   man = transfermarkt %>%
      filter(time_man == t,
             ano_campeonato == s) %>%
      .$valor_equipe_titular_man
   vis = transfermarkt %>%
      filter(time_vis == t,
             ano_campeonato == s) %>%
      .$valor_equipe_titular_vis
   all = c(man, vis)
   team = c(team, t)
   season = c(season, s)
   mean_value = c(mean_value, mean(all, na.rm = TRUE))
 }
}
mean_values = tibble(team, season, mean_value) %>%
 filter(!is.na(mean_value))
```

```
na_man = which(is.na(transfermarkt$valor_equipe_titular_man))
na_vis = which(is.na(transfermarkt$valor_equipe_titular_vis))
sum(na_man == na_vis) / length(na_man == na_vis)
```

[1] 1

Imputando os missings.

Plotando a quantidade de gols de acordo com a (log) diferença do mandante/visitante.

```
transfermarkt = transfermarkt %>%
  mutate(dif_valor = valor_equipe_titular_man - valor_equipe_titular_vis,
         dif_log_valor = log(valor_equipe_titular_man) - log(valor_equipe_titular_vis))
transfermarkt %>%
  arrange(desc(dif_valor)) %>%
  select(ano_campeonato, time_man, time_vis, valor_equipe_titular_man,
         valor equipe titular vis, dif valor)
## # A tibble: 2,279 x 6
##
      ano_campeonato time_man time_vis valor_equipe_ti~ valor_equipe_ti~ dif_valor
##
              <int> <chr>
                             <chr>
                                               90500000
                                                                13650000 76850000
## 1
               2019 Grêmio
                             EC Bahia
## 2
               2019 Grêmio
                             CSA
                                               82500000
                                                                7300000 75200000
## 3
              2019 Flamengo Ceará SC
                                             81000000
                                                                 7800000 73200000
## 4
              2019 Flamengo CSA
                                                                 8700000 71300000
                                             80000000
                                                                 4500000 68400000
## 5
              2019 Grêmio
                            Avaí FC
                                               72900000
               2018 Grêmio
                                                                 7050000 65600000
## 6
                             América-~
                                               72650000
## 7
              2020 Flamengo Fluminen~
                                               74650000
                                                                10050000 64600000
## 8
               2019 Flamengo Vasco da~
                                             83000000
                                                                19050000 63950000
                                                                18700000 63800000
## 9
               2019 Grêmio
                             Botafogo
                                             82500000
## 10
               2020 Flamengo EC Bahia
                                               71150000
                                                                 7600000 63550000
## # ... with 2,269 more rows
transfermarkt %>%
  arrange(dif_valor) %>%
  select(ano_campeonato, time_man, time_vis, valor_equipe_titular_man,
         valor_equipe_titular_vis, dif_valor)
## # A tibble: 2,279 x 6
##
      ano_campeonato time_man time_vis valor_equipe_ti~ valor_equipe_ti~ dif_valor
##
              <int> <chr>
                              <chr>
                                                  <dbl>
                                                                   <dbl>
                                                                             <dbl>
## 1
               2020 Sport Re~ Flamengo
                                                7950000
                                                                75050000 -67100000
## 2
               2020 Coritiba~ Flamengo
                                                6630000
                                                                71500000 -64870000
## 3
               2019 Fortaleza Flamengo
                                                                73650000 -64800000
                                                8850000
## 4
               2019 Chapecoe~ Grêmio
                                               12150000
                                                                76800000 -64650000
               2019 Athletic~ Grêmio
                                                                81150000 -63550000
## 5
                                               17600000
               2020 Fluminen~ Flamengo
## 6
                                                9750000
                                                                71800000 -62050000
## 7
               2019 Botafogo Flamengo
                                                                76000000 -61100000
                                               14900000
## 8
               2018 Fluminen~ Flamengo
                                                                74500000 -60850000
                                               13650000
                                                                78300000 -60700000
## 9
               2019 Cruzeiro Flamengo
                                               17600000
               2019 CSA
                              Santos ~
                                                8100000
                                                                68000000 -59900000
## 10
## # ... with 2,269 more rows
transfermarkt %>%
  arrange(valor equipe titular man) %>%
  select(ano_campeonato, time_man, time_vis, valor_equipe_titular_man,
         valor_equipe_titular_vis, dif_valor)
```

A tibble: $2,279 \times 6$

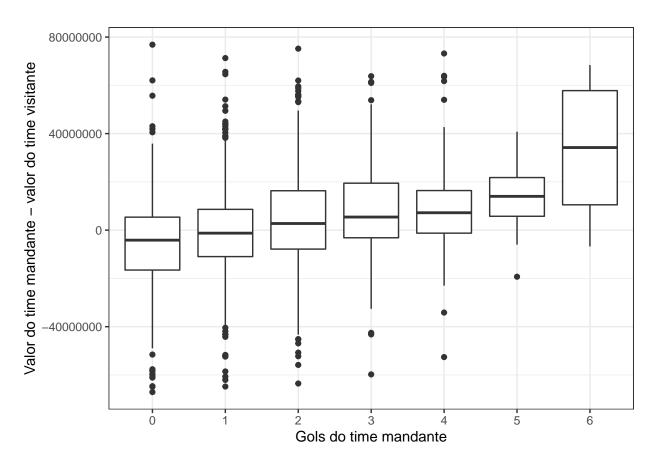
```
##
      ano_campeonato time_man time_vis valor_equipe_ti~ valor_equipe_ti~ dif_valor
##
               <int> <chr>
                              <chr>>
                                                    <dbl>
                                                                     <dbl>
                                                                               <dbl>
                                                                  44950000 -41900000
##
   1
                2018 Paraná
                              Palmeiras
                                                  3050000
                                                 3100000
                                                                  18400000 -15300000
##
    2
                2018 Paraná Internac~
##
                2018 Paraná
                             Atlético~
                                                  3350000
                                                                  16250000 -12900000
##
                2018 Paraná EC Vitór~
                                                  3550000
                                                                   7950000 -4400000
                2018 Paraná
                                                                  31500000 -27770000
                              Corinthi~
                                                  3730000
                2020 Goiás EC Atlético~
                                                                  27900000 -24050000
## 6
                                                  3850000
##
   7
                2019 Avaí FC Fortaleza
                                                  3950000
                                                                   8100000 -4150000
##
                                                                  39200000 -35220000
   8
                2020 Botafogo São Paulo
                                                  3980000
   9
                2019 Avaí FC
                             Vasco da~
                                                 4150000
                                                                  13550000 -9400000
                2018 Paraná
                                                                  14000000 -9600000
## 10
                              Vasco da~
                                                  4400000
## # ... with 2,269 more rows
transfermarkt %>%
  arrange(valor_equipe_titular_vis) %>%
  select(ano_campeonato, time_man, time_vis, valor_equipe_titular_man,
         valor equipe titular vis, dif valor)
## # A tibble: 2,279 x 6
##
      ano_campeonato time_man time_vis valor_equipe_ti~ valor_equipe_ti~ dif_valor
                               <chr>
                                                                               <dbl>
##
               <int> <chr>
                                                   <dbl>
                                                                     <dbl>
                2017 Atlético~ Grêmio
                                                 28000000
                                                                    600000
                                                                            27400000
##
   1
                2019 Goiás EC Grêmio
                                                10400000
                                                                   2800000
                                                                             7600000
                2020 Atlético~ Coritib~
## 3
                                                 5730000
                                                                   2930000
                                                                             2800000
## 4
                2018 Palmeiras EC Vitó~
                                                 43450000
                                                                   3280000 40170000
## 5
                2018 Botafogo Paraná
                                                                   3300000
                                                                            8850000
                                                12150000
## 6
                2020 Ceará SC Botafogo
                                                 6450000
                                                                   3430000
                                                                             3020000
## 7
                2018 EC Bahia Paraná
                                                 11400000
                                                                   3450000
                                                                             7950000
## 8
                2018 Cruzeiro Paraná
                                                29400000
                                                                   3450000
                                                                            25950000
## 9
                2018 Ceará SC Paraná
                                                 7080000
                                                                   3500000
                                                                             3580000
                2016 São Paulo Santa C~
                                                                   3700000 32800000
## 10
                                                36500000
## # ... with 2,269 more rows
transfermarkt %>%
  arrange(desc(valor_equipe_titular_man)) %>%
  select(ano_campeonato, time_man, time_vis, valor_equipe_titular_man,
         valor equipe titular vis, dif valor)
## # A tibble: 2,279 x 6
##
      ano_campeonato time_man time_vis valor_equipe_ti~ valor_equipe_ti~ dif_valor
               <int> <chr>
                              <chr>
##
                                                    <dbl>
                                                                     <dbl>
                                                                               <dbl>
##
  1
                2019 Grêmio
                              EC Bahia
                                                 90500000
                                                                  13650000
                                                                            76850000
                                                                  19050000
                                                                            63950000
##
                2019 Flamengo Vasco da~
                                                 83000000
##
                2019 Grêmio
                                                                  25200000
                                                                            57700000
                              Internac~
                                                 82900000
## 4
                2019 Grêmio
                              Botafogo
                                                 82500000
                                                                  18700000
                                                                            63800000
##
  5
                2019 Grêmio
                                                                   7300000
                              CSA
                                                 82500000
                                                                            75200000
##
                2020 Flamengo Corinthi~
                                                81250000
                                                                  22400000
                                                                            58850000
  7
                2019 Flamengo Ceará SC
                                                                   7800000
                                                                            73200000
##
                                                81000000
##
   8
                2019 Flamengo Palmeiras
                                                80300000
                                                                  54000000
                                                                            26300000
   9
##
                2019 Flamengo Santos FC
                                                80300000
                                                                  30850000 49450000
                2019 Flamengo Internac~
                                                80300000
                                                                  30400000 49900000
```

... with 2,269 more rows

```
transfermarkt %>%
  arrange(desc(valor_equipe_titular_vis)) %>%
  select(ano_campeonato, time_man, time_vis, valor_equipe_titular_man,
        valor_equipe_titular_vis, dif_valor)
## # A tibble: 2,279 x 6
##
      ano_campeonato time_man time_vis valor_equipe_ti~ valor_equipe_ti~ dif_valor
##
              <int> <chr>
                              <chr>
                                                  <dbl>
                                                                  <dbl>
                                                                            <dbl>
##
              2019 Santos FC Flamengo
                                               38300000
                                                               90900000 -52600000
  1
              2019 Palmeiras Flamengo
                                                               89400000 -37650000
## 2
                                              51750000
## 3
              2019 Palmeiras Grêmio
                                              60750000
                                                               82500000 -21750000
              2019 Athletic~ Grêmio
## 4
                                                               81150000 -63550000
                                              17600000
## 5
              2020 São Paulo Flamengo
                                              28300000
                                                               79050000 -50750000
## 6
              2019 Cruzeiro Grêmio
                                               20100000
                                                               78650000 -58550000
## 7
              2019 Cruzeiro Flamengo
                                                               78300000 -60700000
                                              17600000
## 8
              2019 Chapecoe~ Grêmio
                                                               76800000 -64650000
                                             12150000
               2019 Botafogo Flamengo
## 9
                                             14900000
                                                               76000000 -61100000
## 10
               2020 Sport Re~ Flamengo
                                               7950000
                                                               75050000 -67100000
## # ... with 2,269 more rows
p = transfermarkt %>%
  ggplot(aes(x = factor(gols_man), y = dif_valor)) +
 geom_boxplot() +
 theme_bw() +
 xlab("Gols do time mandante") +
```

ylab("Valor do time mandante - valor do time visitante")

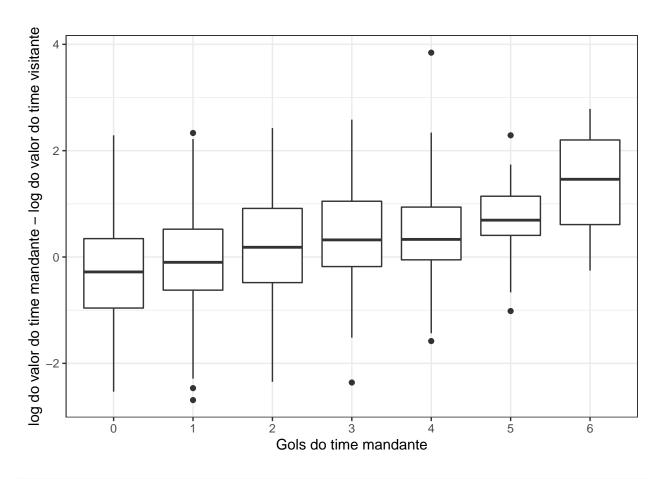
p



```
ggsave(filename = paste0("plots/mandante_sem_log.png"),
    plot = p, width = 10, height = 5, dpi = 1000)
```

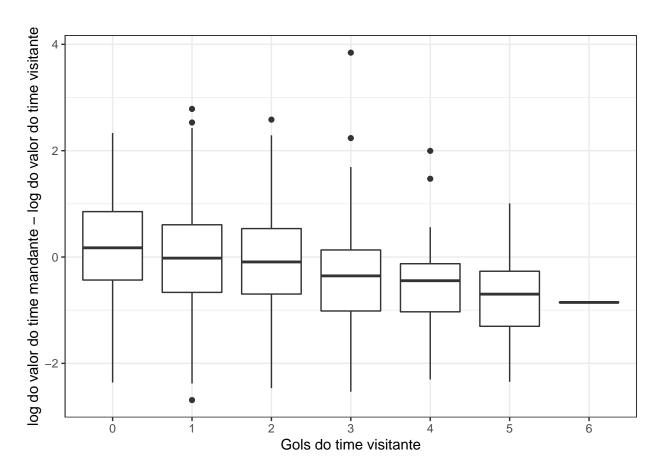
```
p = transfermarkt %>%
  ggplot(aes(x = factor(gols_vis), y = dif_valor)) +
  geom_boxplot() +
  theme_bw() +
  xlab("Gols do time visitante") +
  ylab("Valor do time mandante - valor do time visitante")
ggsave(filename = paste0("plots/visitante_sem_log.png"),
      plot = p, width = 10, height = 5, dpi = 1000)
```

```
p = transfermarkt %>%
  ggplot(aes(x = factor(gols_man), y = dif_log_valor)) +
  geom_boxplot() +
  theme_bw() +
  xlab("Gols do time mandante") +
  ylab("log do valor do time mandante - log do valor do time visitante")
p
```



```
ggsave(filename = paste0("plots/mandante_com_log.png"),
    plot = p, width = 10, height = 5, dpi = 1000)
```

```
p = transfermarkt %>%
    ggplot(aes(x = factor(gols_vis), y = dif_log_valor)) +
    geom_boxplot() +
    theme_bw() +
    xlab("Gols do time visitante") +
    ylab("log do valor do time mandante - log do valor do time visitante")
p
```



cor(transfermarkt\$gols_man, transfermarkt\$dif_valor)

[1] 0.2508633

cor(transfermarkt\$gols_vis, transfermarkt\$dif_valor)

[1] -0.1689147

cor(transfermarkt\$gols_man, transfermarkt\$dif_log_valor)

[1] 0.2657704

cor(transfermarkt\$gols_vis, transfermarkt\$dif_log_valor)

[1] -0.1690221

cor(transfermarkt\$gols_man, transfermarkt\$dif_valor, method = "kendall")

[1] 0.1842327

```
cor(transfermarkt$gols_vis, transfermarkt$dif_valor, method = "kendall")
## [1] -0.1242121
cor(transfermarkt$gols_man, transfermarkt$dif_log_valor, method = "kendall")
## [1] 0.1902347
cor(transfermarkt$gols_vis, transfermarkt$dif_log_valor, method = "kendall")
## [1] -0.1247808
Preparando o data set para juntar com o que temos.
load("~/GitHub/soccer-live-predictions/soccer-live-predictions/scrape/data/results2.RData")
transfermarkt = transfermarkt %>%
  rename(Season = ano_campeonato,
        Home_Team = time_man,
         Away_Team = time_vis,
         Value Home = valor equipe titular man,
         Value_Away = valor_equipe_titular_vis,
         Dif_Value = dif_valor,
         Dif_Log_Value = dif_log_valor) %>%
  select(Season, Home_Team, Away_Team, Value_Home, Value_Away,
         Dif_Value, Dif_Log_Value, rodada)
sort(unique(transfermarkt$Home_Team))
## [1] "América-MG"
                         "Athletico-PR"
                                          "Atlético-GO"
                                                            "Atlético-MG"
## [5] "Avaí FC"
                         "Botafogo"
                                          "Ceará SC"
                                                            "Chapecoense"
## [9] "Corinthians"
                         "Coritiba FC"
                                          "Cruzeiro"
                                                            "CSA"
## [13] "EC Bahia"
                                          "Figueirense FC" "Flamengo"
                         "EC Vitória"
## [17] "Fluminense"
                         "Fortaleza"
                                          "Goiás EC"
                                                            "Grêmio"
## [21] "Internacional" "Joinville-SC"
                                          "Palmeiras"
                                                           "Paraná"
## [25] "Ponte Preta"
                         "RB Bragantino"
                                          "Santa Cruz"
                                                           "Santos FC"
## [29] "São Paulo"
                         "Sport Recife"
                                          "Vasco da Gama"
sort(unique(results$Home_Team))
## [1] "América-MG"
                              "Athletico-PR"
                                                     "Atlético-GO"
                              "Avaí"
                                                     "Bahia"
## [4] "Atlético-MG"
## [7] "Botafogo"
                              "Ceará"
                                                     "Chapecoense"
## [10] "Corinthians"
                              "Coritiba"
                                                     "Cruzeiro"
## [13] "Csa"
                              "Figueirense"
                                                    "Flamengo"
## [16] "Fluminense"
                              "Fortaleza"
                                                     "Goiás"
## [19] "Grêmio"
                              "Internacional"
                                                     "Joinville"
## [22] "Palmeiras"
                              "Paraná"
                                                     "Ponte Preta"
## [25] "Red Bull Bragantino" "Santa Cruz"
                                                    "Santos"
## [28] "São Paulo"
                              "Sport"
                                                    "Vasco da Gama"
## [31] "Vitória"
```

```
transfermarkt$Home_Team[which(transfermarkt$Home_Team == "Avai FC")] =
  "Avaí"
transfermarkt$Away_Team[which(transfermarkt$Away_Team == "Avaí FC")] =
  "Avaí"
transfermarkt$Home Team [which(transfermarkt$Home Team == "Ceará SC")] =
  "Ceará"
transfermarkt$Away Team [which(transfermarkt$Away Team == "Ceará SC")] =
  "Ceará"
transfermarkt$Home_Team[which(transfermarkt$Home_Team == "Coritiba FC")] =
transfermarkt$Away_Team[which(transfermarkt$Away_Team == "Coritiba FC")] =
  "Coritiba"
transfermarkt$Home_Team[which(transfermarkt$Home_Team == "CSA")] =
transfermarkt$Away_Team[which(transfermarkt$Away_Team == "CSA")] =
  "Csa"
transfermarkt$Home_Team[which(transfermarkt$Home_Team == "EC Bahia")] =
transfermarkt$Away Team [which(transfermarkt$Away Team == "EC Bahia")] =
  "Bahia"
transfermarkt$Home Team [which(transfermarkt$Home Team == "EC Vitória")] =
transfermarkt$Away_Team[which(transfermarkt$Away_Team == "EC Vitória")] =
  "Vitória"
transfermarkt$Home_Team[which(transfermarkt$Home_Team == "Figueirense FC")] =
  "Figueirense"
transfermarkt$Away_Team[which(transfermarkt$Away_Team == "Figueirense FC")] =
  "Figueirense"
transfermarkt$Home_Team[which(transfermarkt$Home_Team == "Goiás EC")] =
transfermarkt$Away_Team[which(transfermarkt$Away_Team == "Goiás EC")] =
  "Goiás"
transfermarkt$Home_Team[which(transfermarkt$Home_Team == "Joinville-SC")] =
transfermarkt$Away Team[which(transfermarkt$Away Team == "Joinville-SC")] =
  "Joinville"
transfermarkt$Home_Team[which(transfermarkt$Home_Team == "RB Bragantino")] =
  "Red Bull Bragantino"
transfermarkt$Away_Team[which(transfermarkt$Away_Team == "RB Bragantino")] =
  "Red Bull Bragantino"
transfermarkt$Home_Team[which(transfermarkt$Home_Team == "Santos FC")] =
  "Santos"
transfermarkt$Away_Team[which(transfermarkt$Away_Team == "Santos FC")] =
```

```
"Santos"

transfermarkt$Home_Team[which(transfermarkt$Home_Team == "Sport Recife")] =
    "Sport"

transfermarkt$Away_Team[which(transfermarkt$Away_Team == "Sport Recife")] =
    "Sport"

results = results %>%
    mutate(rodada = ceiling(results$Match/10))
results$rodada[1020] = 28 # https://conteudo.cbf.com.br/sumulas/2017/142261se.pdf
results$rodada[1030] = 27 # https://conteudo.cbf.com.br/sumulas/2017/142271se.pdf

results = left_join(results, transfermarkt)

## Joining, by = c("Season", "Home_Team", "Away_Team", "rodada")

sum(is.na(results))

## [1] 0

save(results, file = "data/results.RData")
```